

Data Science

**Assignment 6 : Frequent Pattern Augmented
Classification Model**



Oleh:

Aditya Murti Kusuma Atmaja 25/563098/PPA/07099

Fawwaz Rif'at Revista 25/565782/PPA/07130

Khalilullah Al Faath 25/566643/PPA/07139

Reza Ananda Hatmi 25/565054/PPA/07124

**PROGRAM MAGISTER ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA**

2026

Daftar Isi

Daftar Isi.....	1
1. Pendahuluan dan Tujuan.....	2
2. Eksplorasi Data dan Langkah Preprocessing.....	2
2.1 Dataset.....	2
2.2 Eksplorasi Awal.....	3
2.2.1. Atribut Dasar Dataset.....	3
2.2.2 Ringkasan statistik deskriptif dataset.....	3
2.2.3 Identify Missing Value.....	4
2.2.4 Uji Normalitas Data.....	4
2.2.5 Pengecekan Outlier.....	6
2.2.6 Categorical Data Exploration.....	7
2.3 Langkah Preprocessing.....	8
2.3.1 Data Splitting.....	8
2.3.2 Imputasi Missing Value.....	9
2.3.3 Rekayasa Fitur (Feature Engineering).....	10
2.3.4 Transformasi dan Scaling.....	10
2.3.5 Seleksi Fitur.....	10
2.3.6 Augmentasi Data (SMOTE-NC).....	10
3. Deskripsi Model.....	10
3.1 Model A Baseline.....	10
3.2 Model B Frequent Pattern Augmented Classification.....	11
4. Pembentukan dan Pemetaan Fitur Baru.....	11
4.1 Konversi Data ke Format Transaksi.....	11
4.2 Penambangan Frequent Itemsets (FP-Growth).....	12
4.3 Pembentukan dan Filterisasi Association Rules.....	12
4.4 Pengkodean Fitur dari Association Rules.....	12
4.5 Augmentasi Fitur (Feature Augmentation).....	12
4.6 Pemetaan ke Data Uji (Tanpa Data Leakage).....	13
5. Perbandingan Performa Model.....	13
5.1 Metrik Evaluasi.....	13
5.2 Hasil Model A (Baseline).....	13
5.3 Hasil Model B (FP-Growth Augmented).....	14
5.4 Perbandingan Langsung Model A vs Model B.....	14
6. Diskusi dan Kesimpulan.....	14
6.1 Dampak Penggunaan Association Rules sebagai Fitur.....	14
6.2 Model Mana yang Lebih Baik dan Mengapa.....	15
6.3 Kelebihan dan Keterbatasan Kedua Pendekatan.....	15
6.3.1 Kelebihan Model A (Baseline).....	15
6.3.2 Keterbatasan Model A.....	15
6.3.3 Kelebihan Model B (FP-Growth Augmented).....	16
6.3.4 Keterbatasan Model B.....	16

1. Pendahuluan dan Tujuan

Penyakit Alzheimer merupakan gangguan neurodegeneratif progresif yang mengakibatkan penurunan fungsi kognitif secara bertahap, terutama pada populasi lansia. Deteksi dini kondisi demensia sangat krusial untuk memperlambat progresi penyakit dan meningkatkan kualitas hidup pasien. Pendekatan *machine learning* telah terbukti mampu mengidentifikasi pola-pola klinis yang relevan dari data kesehatan longitudinal.

Tugas ini merupakan kelanjutan dari proyek sebelumnya (Assignment #5), yaitu sebuah *pipeline machine learning* yang ditingkatkan telah dibangun untuk mengklasifikasikan status demensia pasien ke dalam tiga kelas: *Converted*, *Demented*, dan *Nondemented*. Pada tugas ini, pendekatan tersebut diperluas dengan mengintegrasikan teknik *frequent pattern mining*, khususnya FP-Growth, guna mengekstrak pola-pola asosiasi yang tersembunyi di dalam data sebagai fitur tambahan bagi model klasifikasi.

Tujuan utama dari tugas ini adalah:

- Membangun Model B yang merupakan model klasifikasi berbasis frequent pattern mining dengan menggunakan FP-Growth untuk menambang pola-pola frequent itemset dan association rules dari data latih.
- Menggunakan *association rules* yang ditambang secara eksklusif dari data latih untuk menciptakan fitur-fitur biner baru, kemudian memetakannya ke data uji tanpa data leakage.
- Membandingkan performa Model B (*augmented*) terhadap Model A (*baseline* dari proyek sebelumnya) menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-score*.
- Menganalisis dampak penggunaan *association rules* sebagai fitur tambahan terhadap kemampuan klasifikasi model.

2. Eksplorasi Data dan Langkah Preprocessing

2.1 Dataset

Dataset yang digunakan adalah Dementia Prediction Dataset yang bersumber dari Kaggle (*shashwatwork/dementia-prediction-dataset*). Dataset ini bersifat longitudinal, yaitu setiap pasien dapat memiliki lebih dari satu entri yang merepresentasikan kunjungan MRI yang berbeda. Dataset terdiri dari 373 baris dan 15 kolom, dengan variabel target berupa kolom Group yang memiliki tiga nilai: *Converted* (berubah jadi demensia), *Demented* (sudah demensia), dan *Nondemented* (tidak demensia).

No	Kolom	Deskripsi
1	Visit	Nomor kunjungan pasien (longitudinal)
2	MR Delay	Jarak hari antar kunjungan MRI
3	M/F	Jenis kelamin (M = Laki-laki, F = Perempuan)
4	Age	Usia pasien (60–98 tahun, rata-rata 77)
5	EDUC	Tingkat pendidikan formal (tahun)
6	SES	Status sosial ekonomi (ordinal; 19 missing value)
7	MMSE	Mini-Mental State Examination, skor kognitif (2 missing value)

8	CDR	Clinical Dementia Rating, tingkat keparahan demensia
9	eTIV	Estimated Total Intracranial Volume (cm ³)
10	nWBV	Normalized Whole Brain Volume
11	ASF	Atlas Scaling Factor

Tabel 1. Deskripsi kolom dataset

2.2 Eksplorasi Awal

Sebelum melakukan perlakuan pada dataset, kami melakukan beberapa eksplorasi untuk mengecek atribut dasar dataset, karakteristik deskriptif data, keanomalian pada data (seperti data kosong, pencilan), dan hubungan antarvariabel.

2.2.1. Atribut Dasar Dataset

Dataset dementia prediction terdiri dari 373 baris dan 11 kolom. Gambar 2 menunjukkan contoh sampel data pada dataset.

	Subject ID	MRI ID	Group	Visit	MR Delay	M/F	Hand	Age	EDUC	SES	MMSE	CDR	eTIV	nWBV	ASF
74	OAS2_0037	OAS2_0037_MR3	Demented	3	2029	M	R	88	12	4.0	26.0	0.5	1483	0.709	1.184

Gambar 1: Contoh sampel dataset

Berdasarkan gambar di atas, diidentifikasi kolom-kolom berikut sebagai data berjenis kategorik, di antaranya adalah kolom Group, M/F, Hand, SES, dan CDR, sementara sisanya dianggap sebagai numerik.

2.2.2 Ringkasan statistik deskriptif dataset

Statistik deskriptif dataset adalah proses merangkum dan menyajikan karakteristik dasar dari data secara kuantitatif. Pada tahapan ini digunakan fungsi describe() pada library Pandas. Proses ini bertujuan untuk memetakan metrik tendensi sentral, dispersi, dan mengidentifikasi anomali sebaran data, seperti anomali sebaran data dengan rentang nilai minimum-maksimum atau potensi kemiringan (skewness). Hasil pemanggilan fungsi ditunjukkan oleh Gambar 3.

	Visit	MR Delay	Age	EDUC	SES	MMSE	CDR	eTIV	nWBV	ASF
count	373.000000	373.000000	373.000000	373.000000	354.000000	371.000000	373.000000	373.000000	373.000000	373.000000
mean	1.882038	595.104558	77.013405	14.597855	2.460452	27.342318	0.290885	1488.128686	0.729568	1.195461
std	0.922843	635.485118	7.640957	2.876339	1.134005	3.683244	0.374557	176.139286	0.037135	0.138092
min	1.000000	0.000000	60.000000	6.000000	1.000000	4.000000	0.000000	1106.000000	0.644000	0.876000
25%	1.000000	0.000000	71.000000	12.000000	2.000000	27.000000	0.000000	1357.000000	0.700000	1.099000
50%	2.000000	552.000000	77.000000	15.000000	2.000000	29.000000	0.000000	1470.000000	0.729000	1.194000
75%	2.000000	873.000000	82.000000	16.000000	3.000000	30.000000	0.500000	1597.000000	0.756000	1.293000
max	5.000000	2639.000000	98.000000	23.000000	5.000000	30.000000	2.000000	2004.000000	0.837000	1.587000

Gambar 2: Ringkasan statistik deskriptif tiap kolom numerik

Berdasarkan Gambar 3 di atas, usia pasien berkisar antara 60 hingga 98 tahun, dengan usia rata-rata sekitar 77 tahun. Kelompok ini umumnya berpendidikan tinggi, dengan rata-rata masa pendidikan formal sekitar 14,6 tahun (setara dengan pendidikan perguruan tinggi atau gelar sarjana), dan dengan status sosial ekonomi (SES) menengah. Dari sudut

pandangan klinis dan kognitif, sebagian besar pasien tampaknya sehat, tetapi terdapat rentang yang jelas dari penurunan kognitif. Skor Mini-Mental State Examination (MMSE) memiliki rata-rata 27,34 dan median 29, yang berada dalam rentang kognitif normal. Demikian pula, median Clinical Dementia Rating (CDR) adalah 0 yang menunjukkan tidak adanya demensia pada sebagian besar individu. Meskipun demikian, data ini juga mencakup kasus-kasus gangguan kognitif yang parah dengan skor MMSE turun hingga 4 dan skor CDR mencapai 2, yang mengindikasikan demensia sedang.


Pemeriksaan MRI neurologis sejalan dengan profil kognitif yang bervariasi ini. Estimated Total Intracranial Volume (eTIV) rata-rata sekitar 1.488 cm³, sedangkan Normalized Whole Brain Volume (nWBV) rata-rata 0,729, dengan nilai minimum 0,644 yang menunjukkan atrofi otak yang signifikan pada beberapa pasien. Desain longitudinal studi ini terlihat dari variabel “MR Delay”, yang mengukur jumlah hari antara kunjungan. Variabel ini menunjukkan variasi yang sangat besar, berkisar antara 0 hingga 2.639 hari, menyoroti interval tindak lanjut yang sangat tidak konsisten di antara pasien.


2.2.3 Identify Missing Value

Dari Gambar 3 didapatkan bahwa terdapat dua kolom yang memiliki data yang hilang (*missing value*), yaitu kolom SES dengan data yang hilang sebanyak 19 dan kolom MMSE dengan data yang hilang sebanyak 2.

2.2.4 Uji Normalitas Data

Uji normalitas data dilakukan melalui 2 metode, yaitu uji statistik dengan metode Fisher-Pearson dan visualisasi dengan diagram lonceng (*bell curve*) dan boxplot. Berikut hasil uji normalitas dengan visualisasi Diagram Lonceng (*Bell Curve*) dan Boxplot:





Gambar 3: Visualisasi Uji Normalitas dan Sebaran Data

Berdasarkan Diagram Lonceng, terdapat 3 kategori distribusi data pada dataset ini, yaitu normal, positive skew, dan negative skew. Berdasarkan gambar diagram lonceng, terdapat 4 fitur yang berdistribusi normal, yaitu Age, EDUC, eTIV, nWBVM, dan ASF. Fitur yang bersifat positive skew adalah MR Delay, sedangkan fitur yang bersifat negative skew adalah MMSE. Namun, uji distribusi normalitas data secara visual masih bersifat subjektif, oleh karena itu, perlu digunakan metode uji yang lebih objektif seperti Uji statistik Fisher-Pearson. Tabel 2 menunjukkan hasil uji fitur-fitur numerik dengan menggunakan Fisher-Pearson.

Fitur	Skewness Coefficient
MR Delay	0.9450
Age	0.1417
EDUC	-0.0260
MMSE	-2.3661
eTIV	0.4969
nWBV	0.2346
ASF	0.0835

Tabel 2: Hasil uji Fisher-Pearson pada fitur-fitur numerik

Berdasarkan hasil uji tersebut, terdapat 3 kategori distribusi normalitas datanya, yaitu normal, *moderately skewed*, dan *highly skewed*. Fitur yang berdistribusi normal memiliki nilai *Skewness coefficient* pada rentang -0.5 hingga 0.5, *moderately skewed* berada pada rentang -1.0 hingga -0.5 atau 0.5 hingga 1.0, sedangkan *highly skewed* berada pada nilai <-1.0 atau >1.0. Berdasarkan skor *Skewness coefficient*, diketahui bahwa fitur yang berdistribusi normal adalah Age, EDUC, eTIV, nWBV, ASF, fitur *moderately skewed* adalah MR Delay, dan fitur *highly skewed* adalah MMSE.

2.2.5 Pengecekan Outlier

Uji outlier dilakukan dengan menggunakan Tukey's rule dengan nilai fold 1.5. Rumus dari *Tukey's rule* ditunjukkan oleh (1).

$$\begin{aligned}
 \text{Batas bawah} &= Q_1 - 1.5 * IQR \\
 \text{Batas atas} &= Q_3 + 1.5 * IQR
 \end{aligned}
 \tag{1}$$


Dengan Q_1 adalah kuartil pertama (persentil ke-25), Q_3 adalah kuartil ketiga (persentil ke-75), dan IQR adalah selisih Q_3 dan Q_1 .

	column	mean	std	lower_bound	upper_bound	outliers_count
0	MR Delay	595.104558	635.485118	-1309.500	2182.500	8
1	Age	77.013405	7.640957	54.500	98.500	0
2	EDUC	14.597855	2.876339	6.000	22.000	3
3	MMSE	27.342318	3.683244	22.500	34.500	42
4	eTIV	1488.128686	176.139286	997.000	1957.000	2
5	nWBV	0.729568	0.037135	0.616	0.840	0
6	ASF	1.195461	0.138092	0.808	1.584	1


Tabel 3: Hasil Identifikasi Data *Outliers*

2.2.6 Categorical Data Exploration


Bagian ini menampilkan hasil eksplorasi data kategorikal, yaitu *Group*, *SES*, *Hand*, dan *CDR*.




(a)



(b)



(c)



(d)

2.2.7 Uji Korelasi

Uji korelasi dilakukan untuk mengetahui hubungan tiap fitur terhadap fitur target (status demensia). Terdapat 3 uji statistik yang dilakukan pada penelitian ini, yaitu ANOVA *classifier* (Numerik-Nominal), Rank Spearman (Ordinal-Nominal), dan Chi-Square (Nominal-Nominal). Nilai *alpha* yang digunakan adalah 95% (0.05), sehingga suatu fitur dikatakan berhubungan jika memiliki nilai *P-value* < 0.05. Berikut hasil uji statistik yang dilakukan:

--- Hasil Uji f_classif (Feature Selection) ---				
	Attribute	F-Score	P-Value	
0	median_imputer__MMSE	160.290928	0.0000000	
1	remainder__nWBV	14.499310	0.0000010	
2	remainder__EDUC	11.981794	0.0000099	
3	educ_ses	7.454148	0.0006927	
4	remainder__Age	5.541829	0.0043312	
5	age_nWBV_ratio	4.135730	0.0169118	
6	nWBV_Yearly_Loss	2.837022	0.0601733	
7	remainder__Visit	2.582351	0.0772758	
8	nWBV_Change	2.236079	0.1086551	
9	MMSE_Change	2.187818	0.1139477	
10	remainder__MR Delay	1.597625	0.2040935	
11	remainder__eTIV	0.211583	0.8094227	
Hasil Uji Fitur Kategorik terhadap Group (Nominal & Ordinal)				
	Attribute	Score	P-Value	Method
0	remainder__M/F_M	14.614022	0.0006708	Chi-Square
1	remainder__CDR	-0.762974	0.0000000	Spearman
2	mode_imputer__SES	0.103992	0.0706677	Spearman

Gambar 6: Hasil Uji Statistik Korelasi Fitur Terhadap Status Demensia


Berdasarkan hasil uji statistik diatas, diketahui terdapat 8 fitur yang memiliki hubungan signifikan dengan fitur target (status demensia) karena memiliki nilai $P\text{-value} < 0.05$ (kotak merah), yaitu median_imputer__MMSE, remainder__nWBV, remainder__EDUC, educ_ses, remainder__Age, age_nWBV_ratio, remainder__M/F_M, dan remainder__CDR.

2.3 Langkah Preprocessing

Preprocessing dilakukan dengan mengikuti pipeline yang sama persis dengan proyek sebelumnya untuk menjaga konsistensi baseline. Berikut adalah langkah-langkah yang diterapkan :

2.3.1 Data Splitting

Pada tahapan *splitting data* ini, dilakukan beberapa perbaikan metode splitting untuk mengatasi masalah utama yang ada pada paper baseline. Salah satu kelemahan dari paper baseline adalah melakukan data splitting sesudah *preprocessing* dan hanya menggunakan train-test split biasa, padahal masalah kebocoran data atau data leakage ini merujuk pada data visit. Pada dasarnya, data ini bersifat longitudinal, di mana seorang pasien dapat melakukan kunjungan lebih dari satu kali. Akibatnya data visit pasien terdistribusi ke dalam data *training* maupun data *testing* secara bersamaan, ini menyebabkan model mengenali data pasien sebelum pengujian dilakukan dan menghasilkan evaluasi yang terlalu bias.



Gambar 7: Metodologi *Data Splitting* menggunakan *StratifiedGroupKFold*

Pada tahapanam ini dilakukannya data splitting sebelum dilakukannya tahapan preprocessing data, serta diimplementasikannya pendekatan baru dengan menggunakan *StratifiedGroupKFold* Untuk mencegah terjadinya data leakage Seluruh riwayat data klinis dan pemeriksaan dari satu Subject ID akan dikelompokkan bersama. Dengan kata lain, seluruh data dari pasien tertentu akan dimasukkan sepenuhnya ke dalam training set atau sepenuhnya ke dalam testing set. Tidak ada data dari pasien yang sama yang saling tumpang tindih antara train dan test. Serta digunakannya *Stratified* untuk memastikan proporsi kelas tetap seimbang agar meminimalisir kemungkinan adanya *data leakage*. Untuk pembagian datanya Raw dataset memiliki jumlah total sebanyak 373 dengan 190 Nondemented, 146 Demented, 37 Converted setelah dilakukannya splitting data jumlah data dibagi menjadi dua yaitu training dan testing dengan masing-masing jumlahnya adalah 303 untuk Train set dengan 161 Nondemented, 111 Demented, 31 Converted dan untuk jumlah total testing adalah 70 dengan 35 Nondemented, 29 Demented dan 6 Converted.

2.3.2 Imputasi Missing Value

Dalam dataset yang digunakan dalam percobaan, ditemukannya adanya data yang memiliki nilai yang kosong atau *missing value* yang ditunjukkan pada Tabel 4 berikut.

Fitur	Jumlah <i>missing value</i>
SES	19
MMSE	2

Table 4: Table Missing value

Missing value disini perlu ditangani dengan serius agar dapat menghasilkan hasil improvement yang memuaskan. Maka dari itu, paper *baseline* mengelola missing value dengan menggunakan *Mean* SES, yang tipe datanya adalah kategorikal, dan MMSE yang menggunakan modus ketika tipe datanya numerik. Hal ini menyebabkan fitur pada data kategorikal tidak dapat dilakukan menggunakan operasi matematika, dan pada metode baseline digunakan nilai rata-rata atau mean untuk mengisi data MMSE yang kosong. Padahal data tersebut memiliki banyak outliers dan tidak terdistribusi normal. Hal ini dapat menimbulkan bias sehingga perlunya improvisasi pada penanganan missing value, yaitu dengan menggunakan modus untuk data SES dan median untuk data MMSE, karena itu

dapat mengImputasi dengan nilai yang paling dominan dari dataset, serta median merupakan metrik pemusatan paling *robust* untuk data klinis berkelanjutan.

2.3.3 Rekayasa Fitur (*Feature Engineering*)

Fitur-fitur baru diciptakan untuk mengeksplorasi informasi longitudinal dan hubungan antar variabel klinis:

- educ_ses: interaksi antara pendidikan dan status sosial ekonomi.
- age_nWBV_ratio: rasio usia terhadap volume otak yang dinormalisasi.
- CDR_x_MMSE: interaksi CDR dengan skor kognitif MMSE.
- nWBV_x_CDR_risk: interaksi volume otak dengan profil risiko CDR.
- age_x_CDR_risk: interaksi usia dengan profil risiko CDR.
- MMSE_drop_so_far: penurunan kumulatif skor MMSE dari kunjungan pertama.
- CDR_Change, CDR_Previous: perubahan CDR antar kunjungan.
- nWBV_total_decline, nWBV_Change: laju penurunan volume otak antar kunjungan.
- at_risk_profile: variabel biner yang menandai kombinasi faktor risiko tinggi.
- CDR_ever_nonzero: indikator apakah pasien pernah memiliki CDR > 0.

2.3.4 Transformasi dan Scaling

Transformasi Yeo-Johnson diterapkan pada fitur dengan distribusi skewed untuk menormalkan distribusi dan menstabilkan varians. Selanjutnya, StandardScaler digunakan untuk menstandarkan fitur numerik, One-Hot Encoding untuk fitur nominal (M/F), dan Ordinal Encoding untuk fitur ordinal (SES, CDR).

2.3.5 Seleksi Fitur

Seleksi fitur dilakukan secara statistik menggunakan tiga metode berbeda sesuai tipe fitur: ANOVA F-test (f_{classif}) untuk fitur numerik, Uji Chi-Square untuk fitur nominal, dan Korelasi Spearman untuk fitur ordinal. Hanya fitur dengan $p\text{-value} < 0,05$ yang dipertahankan. Hasilnya, 16 fitur final digunakan untuk training.

2.3.6 Augmentasi Data (SMOTE-NC)

Ketidakseimbangan kelas diatasi menggunakan SMOTE-NC (Synthetic Minority Over-sampling Technique for Nominal and Continuous features) yang mengakomodasi campuran fitur numerik dan kategorikal. Setelah augmentasi, set latih memiliki 483 sampel dengan distribusi seimbang: 161 sampel per kelas.

3. Deskripsi Model

3.1 Model A *Baseline*

Model A merujuk pada hasil terbaik yang diperoleh dari proyek Assignment #4, di mana enam algoritma klasifikasi dilatih pada 16 fitur yang telah diproses melalui pipeline preprocessing di atas. Sesuai dengan ketentuan tugas, hasil evaluasi dari proyek sebelumnya digunakan langsung sebagai baseline tanpa perlu melatih ulang dari awal.

Keenam model yang digunakan adalah:

Model	Deskripsi Singkat
Gaussian Naive Bayes	Klasifikasi probabilistik berbasis Teorema Bayes dengan asumsi independensi fitur. <code>var_smoothing=1e-2</code> .
Decision Tree	Pemisahan rekursif berdasarkan impurity (Gini). <code>max_depth=5</code> , <code>min_samples_leaf=4</code> .
Random Forest	Ensemble 200 pohon keputusan dengan bagging. <code>max_depth=6</code> , <code>min_samples_leaf=3</code> , <code>max_features=sqrt</code> .
XGBoost	Gradient boosting berbasis pohon. <code>max_depth=4</code> , <code>learning_rate=0.05</code> , <code>subsample=0.8</code> , <code>colsample_bytree=0.8</code> , <code>gamma=0.1</code> .
Gradient Boosting	Sequential boosting. <code>n_estimators=150</code> , <code>learning_rate=0.05</code> , <code>max_depth=3</code> , <code>subsample=0.8</code> .
Voting Ensemble	Soft voting dari semua model di atas dengan bobot [1, 1, 2, 2, 2] untuk GNB, DT, RF, XGB, GB.

Tabel 2. Deskripsi model pada Model A

Performa baseline Model A dengan manual tuning dan SMOTE-NC yang digunakan sebagai acuan perbandingan ditunjukkan pada Tabel 5 di bagian perbandingan performa. Hasil terbaik dicapai oleh Random Forest, XGBoost, dan Voting Ensemble dengan akurasi 92,86%.

3.2 Model B Frequent Pattern Augmented Classification

Model B menggunakan arsitektur yang sama dengan Model A namun dengan fitur yang diperluas menggunakan hasil penambangan frequent itemset dan association rules melalui algoritma FP-Growth. Model B dilatih pada data dengan 86 fitur (36 fitur matriks transaksi + 50 fitur biner dari association rules), dibandingkan Model A yang hanya menggunakan 16 fitur.

Seluruh algoritma klasifikasi yang digunakan pada Model B sama persis dengan Model A (Gaussian NB, Decision Tree, Random Forest, XGBoost, Gradient Boosting, dan Voting Ensemble) dengan hyperparameter yang identik, sehingga perbedaan performa antara kedua model semata-mata disebabkan oleh perbedaan ruang fitur.

4. Pembentukan dan Pemetaan Fitur Baru

4.1 Konversi Data ke Format Transaksi

Sebelum menjalankan algoritma FP-Growth, data tabular diubah menjadi format transaksi. Proses konversi dilakukan secara eksklusif pada data latih (`X_train_balanced`, 483 sampel) untuk menghindari data leakage.

Langkah-langkah konversi:

- Fitur kontinu (12 kolom): MMSE, nWBV, Age, EDUC, educ_ses, age_nWBV_ratio, CDR_Change, CDR_x_MMSE, nWBV_x_CDR_risk, age_x_CDR_risk (CDR_Previous dan MMSE_drop_so_far dihilangkan karena hampir konstan) didiskretisasi menggunakan KBinsDiscretizer (`n_bins=3`, strategi kuantil) menjadi label Low/Mid/High.
- Fitur ordinal (CDR): dibulatkan ke nilai valid CDR (0, 0.5, 1, 2, 3) kemudian diberi label CDR=<nilai>.

- Fitur biner ada 3 kolom yaitu M/F_M, CDR_ever_nonzero, at_risk_profile dipertahankan dengan label yang mudah dibaca conothnya M/F_M=1, at_risk_profile=Yes.

Setiap baris data diubah menjadi daftar item (transaction list), kemudian diencode menggunakan Transaction Encoder dari library mlxtend. Hasil akhirnya adalah matriks transaksi biner berukuran 483×36 (36 item unik).

4.2 Penambahan Frequent Itemsets (FP-Growth)

Algoritma FP-Growth diterapkan pada matriks transaksi data latih dengan parameter minimum support = 0,2 (20%). Pemilihan algoritma FP-Growth dibandingkan Apriori karena FP-Growth tidak memerlukan pembangkitan kandidat secara eksplisit sehingga lebih efisien secara komputasi.

- Total frequent itemsets yang ditemukan: 1.146 itemset
- Itemset dengan support tertinggi: CDR_Change=Mid (support 0,996), at_risk_profile=No (support 0,675), nWBV_x_CDR_risk=Low (support 0,665)

4.3 Pembentukan dan Filterisasi Association Rules

Dari frequent itemsets di atas, association rules yang dibentuk dengan minimum confidence = 0,6 menghasilkan 16.458 aturan. Filterisasi dilakukan dalam dua tahap, yaitu:

1. Filter Umum (rules_filtered)
Rules disaring dengan kewajiban untuk memenuhi kriteria confidence $\geq 0,75$, lift $\geq 1,5$, panjang antecedent ≤ 3 , dan konsekuen tunggal, sehingga menghasilkan 718 aturan terfilter.
2. Filter Klinis (rules_clinical)
Berdasarkan hasil dari 718 rules yang telah difilter sebelumnya, dipilih hanya aturan dengan konsekuen yang relevan secara klinis terhadap progresi demensia, yaitu CDR=0, CDR=0.5, CDR=1.0, CDR=2.0, CDR=3.0, at_risk_profile=Yes/No, dan CDR_ever_nonzero=Yes/No. Kriteria lift $\geq 1,2$ dan confidence $\geq 0,75$ digunakan, kemudian menghasilkan 399 aturan klinis.

4.4 Pengkodean Fitur dari Association Rules

Top 50 aturan klinis (diurutkan berdasarkan lift tertinggi) digunakan untuk membuat 50 fitur biner baru. Mekanisme pengkodean Association Rules:

- Nilai = 1 jika seluruh item antecedent suatu aturan terpenuhi pada suatu instansi atau baris.
- Nilai = 0 jika ada antecedent yang tidak terpenuhi.

Nama fitur dikodekan sebagai rule_<index>_<konsekuen> untuk memudahkan interpretasi. Implementasi penyandian ini hanya menggunakan aturan yang ditambah dari data train.

4.5 Augmentasi Fitur (Feature Augmentation)

Fitur-fitur baru tersebut digabungkan dengan matriks transaksi biner (36 fitur) untuk membentuk ruang fitur final:

- Fitur matriks transaksi (36 kolom): representasi biner dari diskretisasi 16 fitur asli.
- Fitur association rules (50 kolom): fitur biner dari top 50 aturan klinis.

- Sisa fitur dari dataset asli
- Total: 100 fitur untuk Model B.

4.6 Pemetaan ke Data Uji (Tanpa Data Leakage)

Agar tidak terjadi data leakage pemetaan fitur ke data uji dilakukan secara ketat dengan langkah berikut:

- KBinsDiscretizer yang dilatih pada data latih kbd digunakan untuk mengubah fitur kontinu data uji (kbd.transform, bukan fit_transform).
- Label diskretisasi (Low/Mid/High) yang sama diterapkan ke data uji kontinu.
- Fungsi encode_rules diimplementasikan pada data uji dengan memanfaatkan objek rules_clinical yang sama diekstraksi secara eksklusif dari data latih. Algoritma FP-Growth tidak dijalankan ulang pada data uji untuk memastikan pola yang dievaluasi murni berasal dari data latih
- Pengujian konsistensi dilakukan menggunakan fungsi assert guna menjamin bahwa data latih dan data uji memiliki ruang fitur yang identik, baik dari segi jumlah maupun urutan kolom (86 kolom).

Hasil akhir: X_train_final berukuran 483×100 dan X_test_final berukuran 70×100 .

5. Perbandingan Performa Model

5.1 Metrik Evaluasi

Perbandingan dilakukan menggunakan empat metrik standar evaluasi klasifikasi yang dilaporkan sebagai Macro Average untuk memberikan penilaian yang adil terhadap ketiga kelas termasuk kelas minoritas (Converted):

- **Accuracy:** proporsi prediksi benar terhadap total prediksi.
- **Macro Precision:** rata-rata presisi tiap kelas.
- **Macro Recall:** rata-rata recall tiap kelas.
- **Macro F1-score:** rata-rata harmonic mean dari Precision dan Recall tiap kelas.

5.2 Hasil Model A (Baseline)

Berikut adalah hasil evaluasi Model A yang mana pada table yang memiliki performa tertinggi yaitu random forest, XGBoost dan Voting ensemble sebagai berikut :

Model	Accuracy (%)	Macro Precision (%)	Macro Recall (%)	Macro F1-Score (%)
Gaussian Naive Bayes	90,00	78,00	70,00	71,00
Decision Tree	82,86	71,00	74,00	71,00
Random Forest	92,86	95,00	77,00	80,00
XGBoost	92,86	85,00	77,00	79,00
Gradient Boosting	91,43	79,00	76,00	77,00
Voting Ensemble	92,86	85,00	77,00	79,00

Tabel 3. Hasil evaluasi Model A

5.3 Hasil Model B (FP-Growth Augmented)

Berikut adalah hasil evaluasi Model B yang memiliki 100 fitur dimana 36 fitur transaksi dan 50 fitur association rules, dan sisanya adalah fitur asli dari dataset

Model	Accuracy (%)	Macro Precision (%)	Macro Recall (%)	Macro F1-Score (%)
Gaussian Naive Bayes	90,00	60,02	65,52	62,64
Decision Tree	90,00	75,79	74,72	75,12
Random Forest	87,14	69,11	67,82	68,13
XGBoost	91,43	83,75	75,48	77,73
Gradient Boosting	94,29	95,95	77,78	81,22
Voting Ensemble	92,86	94,97	76.63	80,19

Tabel 4. Hasil evaluasi Model B

5.4 Perbandingan Langsung Model A vs Model B

Tabel berikut merangkum perbandingan langsung antara model A dan Model B yang mana yang terbaik dari masing-masing pendekatan:

Model	Accuracy	Precision	Recall	F1-Score
Gaussian Naive Bayes	0,00%	-23,05%	-6,40%	-11,77%
Decision Tree	8,62%	6,75%	0,97%	5,80%
Random Forest	-6,16%	-27,25%	-11,92%	-14,84%
XGBoost	-1,54%	-1,47%	-1,97%	-1,61%
Gradient Boosting	3.13%	21,46%	2,34%	5,48%
Voting Ensemble	0,00%	11,73%	-0,48%	1,51%

Tabel 5. Perbandingan Model A vs Model B

6. Diskusi dan Kesimpulan

6.1 Dampak Penggunaan Association Rules sebagai Fitur

Penggunaan fitur berbasis *association rules* memberikan dampak yang sangat bervariasi (*algorithm-dependent*). Berlawanan dengan asumsi awal bahwa diskretisasi akan menurunkan performa secara menyeluruh, pendekatan ini justru mampu mendongkrak performa beberapa model. Penurunan performa terjadi secara drastis pada Random Forest, namun di sisi lain, metrik Gradient Boosting, Decision Tree, dan presisi pada Voting Ensemble justru meningkat. Beberapa faktor yang menjelaskan fenomena ini:

- Karakteristik Pembelajaran Algoritma, Model *boosting* sekuensial seperti Gradient Boosting terbukti sangat handal dalam mengekstrak sinyal dari *sparse matrix* (fitur biner) dan memanfaatkan fitur aturan diskret untuk membuat batas keputusan yang

tajam. Sebaliknya, Random Forest yang membangun banyak *tree* secara acak dengan banyaknya fitur biner yang saling berkorelasi (*redundant*).

- Pengaruh Transformasi Representasi (Trade-off), Data asli yang kaya informasi numerik digantikan oleh 36 matriks transaksi biner (diskretisasi ke *Low*, *Mid*, *High*). Hal ini menyebabkan hilangnya gradasi kuantitatif penting (seperti pada fitur MMSE dan nWBV). Bagi model tertentu (RF, Gaussian NB), hilangnya informasi ini berdampak fatal. Namun bagi algoritma seperti Decision Tree, fitur aturan biner ini justru mempermudah proses pemisahan (*splitting*) di tiap *node*.
- Redundansi dan Kolinearitas Fitur Dari 86 fitur di Model B, sebagian besar merupakan derivasi *frequent itemset* yang sering muncul bersamaan. Ini memicu multikolinearitas yang tinggi, yang bisa mengecoh algoritma tertentu sehingga kesulitan menemukan sinyal murni.
- Tingginya Dimensionalitas Relatif terhadap Ukuran Dataset Dataset hanya memiliki 483 sampel latih, sementara Model B dipaksa memproses 86 fitur. Rasio yang sempit (sekitar 5,6:1) ini memperbesar risiko *overfitting* atau ketidakmampuan model untuk menggeneralisasi pola, yang terlihat pada penurunan performa beberapa model.

6.2 Model Mana yang Lebih Baik dan Mengapa

Secara keseluruhan, tidak ada pendekatan tunggal yang menang mutlak di seluruh algoritma. Model A lebih stabil secara rata-rata, namun model tunggal dengan performa tertinggi (Champion Model) diraih oleh Gradient Boosting dari Model B dengan akurasi 94,29% dan Macro F1-score 81,22%. Nilai ini mengalahkan model terbaik dari Model A (Random Forest: akurasi 92,86%, Macro F1-score 80,00%).

- Mengapa Model B (Gradient Boosting) bisa menjadi yang terbaik? Gradient Boosting pada Model B mampu mengeksplorasi pola kombinasi bersyarat (*if-then condition*) dari *association rules* yang tidak bisa ditangkap oleh analisis fitur tunggal di Model A. Aturan-aturan ini bertindak sebagai "jalan pintas" logika klinis yang mempercepat dan mempertajam akurasi prediksi.
- Mengapa Model A secara rata-rata lebih stabil? Model A menang secara konsistensi karena ia mempertahankan representasi numerik asli dan menggunakan teknik *feature selection* yang ketat (sehingga rasio sampel terhadap fitur sangat sehat, yaitu 30:1). Teknik SMOTE-NC pada ruang fitur kontinu di Model A juga lebih natural dalam menangani ketidakseimbangan kelas dibandingkan manipulasi kelas pada fitur yang sudah menjadi biner.

6.3 Kelebihan dan Keterbatasan Kedua Pendekatan

6.3.1 Kelebihan Model A (Baseline)

- Mempertahankan presisi dan gradasi kuantitatif dari fitur numerik.
- Memberikan performa yang stabil dan *robust* pada hampir seluruh jenis algoritma klasifikasi.
- Efisien secara komputasi, dengan *pipeline* yang ringkas, dan meminimalisir risiko *overfitting* pada dataset berukuran kecil.

6.3.2 Keterbatasan Model A

- Fitur yang digunakan bersifat individual, sehingga kehilangan kesempatan untuk menemukan interaksi multi-fitur yang tersembunyi.

- Batas maksimal performanya tertahan pada kombinasi matematis standar tanpa mengeksploitasi aturan logika yang memiliki makna khusus.

6.3.3 Kelebihan Model B (FP-Growth Augmented)

- Mampu mencetak performa tertinggi dengan mengekspos pola *co-occurrence* antar fitur.
- Fitur bersifat interpretabel secara klinis. Setiap fitur mewakili profil pasien yang spesifik sebagai contoh jika CDR_Change=Mid DAN age_x_CDR_risk=Low, maka risiko Converted berubah
- Sangat bersinergi dengan algoritma berbasis *tree* yang sekuensial (*Gradient Boosting*).

6.3.4 Keterbatasan Model B

- Performa sangat sensitif dan fluktuatif tergantung pemilihan model. Model tertentu seperti Random Forest dan Gaussian NB justru menurun performanya.
- Kehilangan informasi gradasi akibat proses binerisasi paksa (diskretisasi ke *Low/Mid/High*).
- Dimensionalitas membengkak tajam sehingga memperbesar beban memori dan risiko redundansi, sementara pola fitur baru seringkali tetap bias pada kelas mayoritas (Nondemented).

6.4 Kesimpulan

Eksperimen ini menunjukkan bahwa augmentasi fitur berbasis association rules memberikan **hasil kompromi (trade-off) yang bergantung pada algoritma (algorithm-dependent)**. Pendekatan diskretisasi dan penambahan aturan (Model B) tidak serta-merta menurunkan performa, melainkan berhasil mencetak model terbaik secara keseluruhan (Gradient Boosting dengan F1-Score 81,22%). Namun, strategi ini juga terbukti merugikan algoritma lain yang sensitif terhadap hilangnya informasi numerik dan tingginya redundansi fitur biner (seperti Random Forest)